1.2 Przegląd modeli: Różnice między GPT-4o, Claude 3.5 Sonnet a modelami lokalnymi (Llama 3)

Moduł 1: Fundamenty i Mechanizmy LLM

Krzysztof Rytlewski · 2026

Krajobraz modeli językowych — orientacja w terenie

Świat LLM zmienia się w zawrotnym tempie. Dla AI developera kluczowe jest nie tyle znanie każdego benchmarku, co rozumienie osi decyzyjnych: kiedy sięgnąć po GPT-4o, kiedy po Claude 3.5 Sonnet, a kiedy uruchomić model lokalnie.

Główne kryteria podziału modeli:

- **Dostęp:** API w chmurze (OpenAI, Anthropic, Google) vs. modele open-weight uruchamiane lokalnie (Llama, Mistral, Phi)
- **Rozmiar:** liczba parametrów — od kilku miliardów (7B, 8B) do setek miliardów
- **Specjalizacja:** modele ogólne vs. dedykowane (kod, matematyka, medycyna)
- **Koszt licencji:** modele komercyjne z zamkniętymi wagami vs. otwarte (open-weight)

GPT-4o — multimodalny model flagowy OpenAI

GPT-4o (*omni*) łączy rozumienie tekstu, obrazów i dźwięku w jednym modelu end-to-end.

Mocne strony:

- Doskonałe rozumowanie wieloetapowe i realizacja złożonych poleceń
- Natywna obsługa obrazów — analiza zrzutów ekranu, diagramów, kodu ze zdjęć
- Bardzo duże okno kontekstowe — 128 000 tokenów
- Dojrzała integracja z ekosystemem OpenAI: Assistants API, function calling, batch processing

Ograniczenia:

- Zamknięte wagi — brak lokalnego uruchomienia ani swobodnego fine-tuningu poza API
- Koszty wywołań mogą szybko rosnąć przy dużej skali

Kiedy wybrać: produkcyjne aplikacje wymagające niezawodności, multimodalność (obraz + tekst), integracje z ekosystemem OpenAI.

Claude 3.5 Sonnet — model Anthropic i Constitutional AI

Claude 3.5 Sonnet wyróżnia się cechami istotnymi dla zastosowań biznesowych i deweloperskich.

- **Okno kontekstowe 200 000 tokenów** — umożliwia analizę całych repozytoriów kodu lub długich dokumentów prawnych w jednym wywołaniu
- **Wyjątkowa jakość kodu** — w benchmarku SWE-bench osiągał czołowe wyniki spośród modeli komercyjnych
- **Constitutional AI** — technika trenowania oparta na zestawie zasad etycznych; w praktyce zwiększa przewidywalność i zmniejsza halucynacje
- **Niezawodne śledzenie długich instrukcji** — model rzadziej „gubi" kontekst z początku długiego promptu

Kiedy wybrać: analiza dużych ilości kodu lub dokumentów, generowanie i refaktoryzacja kodu, aplikacje wymagające wysokiej spójności i niezawodności.

Llama 3 i modele open-weight — wolność i odpowiedzialność

Llama 3 (Meta AI) to rodzina modeli open-weight dostępna w wariantach 8B, 70B i 405B parametrów. Kluczowa cecha: **uruchamiają się lokalnie**.

Zalety:

- **Prywatność danych** — żadne dane nie opuszczają własnej infrastruktury; kluczowe w sektorach regulowanych (zdrowie, finanse, prawo)
- **Brak opłat per token** — koszt to infrastruktura (GPU/CPU), nie subskrypcja API
- **Pełna kontrola** — możliwość fine-tuningu na własnych danych i integracji z dowolną infrastrukturą

Ograniczenia:

- Wymagają GPU: model 8B potrzebuje 8–16 GB VRAM; 70B wymaga konfiguracji wielokartowej lub kwantyzacji
- Jakość generowania zazwyczaj niższa niż flagowych modeli komercyjnych, choć różnica z generacji na generację maleje

Narzędzia do uruchamiania modeli lokalnych

Uruchomienie modeli lokalnych jest dziś proste dzięki dedykowanym narzędziom:

- **Ollama** — najprostsza metoda: model uruchamia się jedną komendą w terminalu; automatycznie wystawia API kompatybilne z OpenAI
- **LM Studio** — graficzny interfejs z wbudowanym serwerem API; idealny do eksploracji i testowania modeli bez pisania kodu
- **vLLM** — wydajny serwer inferencji klasy produkcyjnej; obsługuje batching i wysoką przepustowość dla środowisk serwerowych

Wszystkie trzy narzędzia wystawiają API kompatybilne z OpenAI, co umożliwia przełączanie między modelem lokalnym a chmurowym bez zmiany kodu aplikacji.

Porównanie modeli — tabela zestawcza

Cecha	GPT-4o	Claude 3.5 Sonnet	Llama 3 (70B)
Producent	OpenAI	Anthropic	Meta AI
Okno kontekstowe	128 000 tokenów	200 000 tokenów	Do 131 072 tokenów
Dostęp	API w chmurze	API w chmurze	Lokalne / własna chmura
Prywatność danych	Wysyłane do OpenAI	Wysyłane do Anthropic	W pełni lokalna
Multimodalność	Tekst, obraz, dźwięk	Tekst, obraz	Tekst (warianty Vision)
Fine-tuning	Ograniczony przez API	Niedostępny	Pełny dostęp
Koszt użycia	Per token	Per token	Infrastruktura własna
Jakość kodu	Bardzo wysoka	Bardzo wysoka	Wysoka (70B+)

Benchmarki — co mierzą i jak je czytać

- **MMLU** — wiedza ogólna i rozumowanie w 57 dziedzinach; miernik „encyklopedyczności" modelu
- **HumanEval / MBPP** — rozwiązywanie zadań algorytmicznych; benchmark jakości generowania kodu
- **SWE-bench** — realne bugi z GitHuba do naprawienia; najbardziej praktyczny benchmark dla AI developera
- **GPQA** — pytania z fizyki, chemii i biologii na poziomie doktoratu; mierzy głębokie rozumowanie

Benchmarki mogą wprowadzać w błąd przez data contamination (modele trenowane na zestawach testowych) oraz słabą przeliczalność wyników na konkretne zadania.

Rekomendacja: testuj model na własnym zestawie promptów reprezentatywnych dla projektu — godzina testów własnoręcznych daje więcej informacji niż dziesiątki artykułów porównawczych.

Strategia wyboru modelu — model routing

W praktyce wiele projektów korzysta z **kombinacji modeli** dopasowanych do zadania (*model routing*):

- **Szybkie, tanie zadania** (klasyfikacja, ekstrakcja, formatowanie) → `gpt-4o-mini` lub mały model lokalny
- **Złożone rozumowanie i generowanie kodu** → GPT-4o lub Claude 3.5 Sonnet
- **Dokumenty wrażliwe, dane regulowane** → Llama 3 lokalnie
- **Fine-tuning do wąskiej domeny** → otwarty model (Llama, Mistral) dotrenowany na własnych danych

Decyzja to kompromis między **jakością**, **kosztem**, **prywatnością** i **kontrolą**. Świadomy AI developer potrafi uzasadnić ten wybór wobec klienta i zespołu.

Kluczowe wnioski — sekcja 1.2

- Nie istnieje jeden „najlepszy" model — każdy ma inne mocne strony, a wybór zależy od wymagań projektu
- GPT-4o: niezawodność, multimodalność, dojrzały ekosystem; Claude 3.5 Sonnet: długi kontekst, precyzja instrukcji, jakość kodu
- Modele open-weight (Llama 3) zapewniają pełną prywatność i kontrolę, kosztem zarządzania własną infrastrukturą
- Produkcyjne systemy coraz częściej stosują routing modeli — różne modele do różnych zadań w zależności od kosztu i wymaganej jakości odpowiedzi